



Εθνικό και Καποδιστριακό Πανεπιστήμιο Αθηνών

Τμήμα Πληροφορικής και Τηλεπικοινωνιών

Πειραματική Μελέτη:

**Αναζήτηση διανυσμάτων (LSH, Μείωση διαστάσεως με τυχαιοκρατική
προβολή, IVFFlat, IVFPQ)**

1η Προγραμματιστική Εργασία στο Μάθημα:

«Ανάπτυξη Λογισμικού για Αλγοριθμικά Προβλήματα»

Ζαχαρίας Βασίλειος

1115201900275

sdi1900275@di.uoa.gr

Καραγιάννης Δημήτριος

1115202200293

sdi2200293@di.uoa.gr

Περιεχόμενα

Πίνακας Εικόνων	2
Εισαγωγή.....	3
Διαγράμματα και πίνακας με default τιμές	4
Υπολογισμός καλύτερων k clusters μέσω silhouette.....	13
Διαγράμματα και πίνακας με Α φάση αλλαγών	14
Διαγράμματα και πίνακας με Β φάση αλλαγών	23
Διαγράμματα και πίνακας με Γ φάση αλλαγών	32

Πίνακας Εικόνων

Εικόνα 1: Πίνακας με default τιμές.....	6
Εικόνα 2: Διάγραμμα AF με default τιμές.....	8
Εικόνα 3: Διάγραμμα Recall με default τιμές.....	9
Εικόνα 4: Διάγραμμα QPS με default τιμές.....	10
Εικόνα 5: Διάγραμμα tApproximate με default τιμές	11
Εικόνα 6: Διάγραμμα tTrue με default τιμές	12
Εικόνα 7: Διάγραμμα Trade-off με default τιμές.....	13
Εικόνα 8: Πίνακας με silhouette score για kclusters	14
Εικόνα 9: Πίνακας στην Α φάση.....	16
Εικόνα 10: Διάγραμμα AF Α φάσης.....	18
Εικόνα 11: Διάγραμμα Recall Α φάσης.....	19
Εικόνα 12: Διάγραμμα QPS Α φάσης.....	20
Εικόνα 13: Διάγραμμα tApproximate Α φάσης	21
Εικόνα 14: Διάγραμμα tTrue Α φάσης	22
Εικόνα 15: Διάγραμμα Trade-off Α φάσης.....	23
Εικόνα 16: Πίνακας στην Β φάση	25
Εικόνα 17: Διάγραμμα AF Β φάσης.....	27
Εικόνα 18: Διάγραμμα Recall Β φάσης.....	28
Εικόνα 19: Διάγραμμα QPS Β φάσης.....	29
Εικόνα 20: Διάγραμμα tApproximate Β φάσης	30
Εικόνα 21: Διάγραμμα tTrue Β φάσης	31
Εικόνα 22: Διάγραμμα Trade-off Β φάσης	32
Εικόνα 23: Πίνακας στην Γ φάση.....	34
Εικόνα 24: Διάγραμμα AF Γ φάσης	36
Εικόνα 25: Διάγραμμα Recall Γ φάσης.....	37
Εικόνα 26: Διάγραμμα QPS Γ φάσης.....	38
Εικόνα 27: Διάγραμμα tApproximate Γ φάσης.....	39
Εικόνα 28: Διάγραμμα tTrue Γ φάσης.....	40
Εικόνα 29: Διάγραμμα Trade-off Γ φάσης.....	41

Εισαγωγή

Στην παρούσα πειραματική μελέτη εξετάζονται τέσσερις αλγόριθμοι προσεγγιστικής αναζήτησης πλησιέστερων γειτόνων (Approximate Nearest Neighbor Search):

- Locality Sensitive Hashing (LSH)
- Hypercube
- IVF Flat
- IVF PQ

Η αξιολόγηση έγινε σε δύο σύνολα δεδομένων: **MNIST** και **SIFT**, χρησιμοποιώντας **10000 σημεία αναφοράς** και **100 ερωτήματα**. Σκοπός είναι η σύγκριση των αλγορίθμων ως προς:

- το μέσο κλάσμα προσέγγισης,
- την ανάκληση στους **N** πλησιέστερους γείτονες,
- και τον αριθμό ερωτημάτων ανά δευτερόλεπτο (**Queries/sec**).

Για την αξιολόγηση λήφθηκε και υπ' όψη το silhouette score για τα καλύτερα **k** clusters.

Διαγράμματα και πίνακας με default τιμές

Αρχικά πραγματοποιήθηκαν μετρήσεις χρησιμοποιώντας τις **προεπιλεγμένες (default) παραμέτρους** κάθε μεθόδου.

Ειδικότερα, για τη μέθοδο **LSH (Locality Sensitive Hashing)** χρησιμοποιήθηκαν οι εξής τιμές:

- **seed = 1** (για αναπαραγωγισιμότητα ψευδοτυχαίοι αριθμοί)
- **k = 4** (αριθμός συναρτήσεων κατακερματισμού ανά πίνακα)
- **L = 5** (αριθμός πινάκων κατακερματισμού)
- **N = 1** (αναζήτηση του κοντινότερου γείτονα)
- **w = 4.0** (δεκαδικός αριθμός του μήκους του κελιού επί της ευθείας προβολής)
- **R = 2000** για το **MNIST** και **R = 2** για το **SIFT** (δεκαδικός αριθμός ακτίνας αναζήτησης)

Έπειτα, για τη μέθοδο **Hypercube** χρησιμοποιήθηκαν οι εξής τιμές:

- **seed = 1** (για αναπαραγωγισιμότητα ψευδοτυχαίοι αριθμοί)
- **kproj = 14** (διάσταση προβολής σημείων)
- **M = 10** (μέγιστο επιτρεπόμενο πλήθος υποψήφιων σημείων προς έλεγχο)
- **probes = 2** (το μέγιστο επιτρεπόμενο πλήθος κορυφών του υπερκύβου προς έλεγχο)
- **N = 1** (αναζήτηση του κοντινότερου γείτονα)
- **w = 4.0** (δεκαδικός αριθμός του μήκους του κελιού επί της ευθείας προβολής)

- **R = 2000** για το **MNIST** και **R = 2** για το **SIFT** (δεκαδικός αριθμός ακτίνας αναζήτησης)

Ύστερα, για τη μέθοδο **IVF FLAT** χρησιμοποιήθηκαν οι εξής τιμές:

- **seed = 1** (για αναπαραγωγισιμότητα ψευδοτυχαίοι αριθμοί)
- **kclusters = 50**, (ο αριθμός των clusters που θα δημιουργηθούν,)
- **nprobe = 5** (ο αριθμός των πλησιέστερων clusters που θα ελεγχθούν κατά την αναζήτηση)
- **N = 1** (αναζήτηση του κοντινότερου γείτονα)
- **R = 2000** για το **MNIST** και **R = 2** για το **SIFT** (δεκαδικός αριθμός ακτίνας αναζήτησης)

Τέλος, για τη μέθοδο **IVF PQ** χρησιμοποιήθηκαν οι εξής τιμές:

- **seed = 1** (για αναπαραγωγισιμότητα ψευδοτυχαίοι αριθμοί)
- **kclusters = 50**, (ο αριθμός των clusters που θα δημιουργηθούν,)
- **nprobe = 5** (ο αριθμός των πλησιέστερων clusters που θα ελεγχθούν κατά την αναζήτηση)
- **nbits = 8** (ο αριθμός των συστάδων 2^{nbits} της συσταδοποίησης στους M υποχώρους)
- **M = 16** (ο αριθμός των υποδιανυσμάτων M για τον Κβαντισμό Γινομένου)
- **N = 1** (αναζήτηση του κοντινότερου γείτονα)
- **R = 2000** για το **MNIST** και **R = 2** για το **SIFT** (δεκαδικός αριθμός ακτίνας αναζήτησης)

Με τις τιμές αυτές εκτελέστηκαν οι αρχικές μετρήσεις απόδοσης, ώστε να αποτελέσουν σημείο αναφοράς για τις επόμενες ρυθμίσεις παραμέτρων.

	A	B	C	D	E	F	G	H
1	Method	Dataset	Range Search	Average AF	Recall@N	QPS	tApproximateA	tTrueAverage
2	IVFPQ	MNIST	True	1,230.78	0.46	1,156.72	0.43	4.11
3	IVFPQ	SIFT	True	241.11	0.66	5,598.61	0.09	0.68
4	HYPERCUBE	MNIST	False	1.80	0	93,842.79	0.01	3.65
5	HYPERCUBE	SIFT	False	2.07	0	200,862.10	0.00	0.60
6	IVFPQ	MNIST	False	1,230.78	0.46	2,082.98	0.48	4.05
7	IVFFLAT	MNIST	True	1.00	0.99	444.47	1.14	4.04
8	HYPERCUBE	MNIST	True	1.80	0	55,950.91	0.01	3.75
9	IVFFLAT	MNIST	False	1.00	0.99	835.26	1.19	3.84
10	IVFFLAT	SIFT	False	1.00	0.98	6,177.77	0.16	0.64
11	IVFPQ	SIFT	False	241.11	0.66	11,579.46	0.08	0.74
12	LSH	MNIST	True	0	0	71,361.08	0.01	4.01
13	LSH	MNIST	False	0	0	138,658.95	0.01	3.59
14	HYPERCUBE	SIFT	True	2.07	0	110,795.84	0.00	0.63
15	LSH	SIFT	True	0	0	283,849.80	0.00	0.65
16	IVFFLAT	SIFT	True	1.00	0.98	3,381.86	0.15	0.61
17	LSH	SIFT	False	0	0	408,916.00	0.00	0.60

Εικόνα 1: Πίνακας με default τιμές

Είναι γνωστό ότι το **Average AF (Approximation Factor)** δείχνει πόσο **μεγαλύτερη** είναι κατά μέσο όρο η απόσταση του προσεγγιστικού γείτονα σε σχέση με του αληθινού.

- Ιδανικά θέλουμε **AF $\approx$ 1.0**, δηλαδή “βρήκαμε τον σωστό γείτονα”.

Επιπροσθέτως, το **Recall@N** δείχνει το ποσοστό των **πραγματικών N πλησιέστερων** που εντοπίστηκαν μέσα στους N προσεγγιστικούς. Αυτό σημαίνει ότι:

- 1.0 = τέλειο (όλοι οι πραγματικοί βρέθηκαν).
- 0.0 = κανένας πραγματικός δεν εντοπίστηκε.

Προσέτι, το **QPS** (Queries per Second) δείχνει τις αναζητήσεις το δευτερόλεπτο. Άρα θέλουμε όσο το δυνατόν πιο μεγάλο νούμερο.

Συνάμα, το **tApproximateAverage** αποτελεί τον μέσο χρόνο αναζήτησης ανά query σε μικροδευτερόλεπτα.


Τέλος, το **tTrueAverage** είναι ο ακριβής (εξαντλητικός) υπολογισμός ανά query, σε μικροδευτερόλεπτα.

Σύμφωνα λοιπόν, με τον πίνακα της **Εικόνας 1** (Πίνακας με default τιμές):


- ✓ Ο LSH είναι εξαιρετικά γρήγορος, με πολύ μικρό χρόνο ανά query (0.002–0.007 ms). Όμως έχει Recall = 0.0 και AF = 0, πράγμα που σημαίνει ότι δεν επιστρέφει καθόλου σωστούς γείτονες. Συνεπώς, έχουμε σαφές trade-off: ταχύτητα στο έπακρο, αλλά μηδενική ακρίβεια. Συνολική αξιολόγηση: Πολύ γρήγορος, αναποτελεσματικός ως προς τα αποτελέσματα.
- ✓ Ο Hypercube έχει $AF \approx 2$, άρα επιστρέφει γείτονες σε διπλάσια περίπου απόσταση από τους πραγματικούς. Recall = 0.0 → πρακτικά δεν βρίσκει κανέναν ακριβή γείτονα. Είναι πολύ ταχύτερος από το IVFFlat, αλλά χειρότερος σε ποιότητα. Συνολική αξιολόγηση: Καλή ταχύτητα, αλλά ανεπαρκής ακρίβεια· ίσως χρειάζεται αύξηση probes ή M.
- ✓ Ο IVF FLAT έχει $AF \approx 1$ → σχεδόν τέλεια προσέγγιση (οι αποστάσεις ίδιες με της ακριβούς αναζήτησης). Recall ≈ 0.98 –0.99 → σχεδόν όλοι οι πραγματικοί γείτονες βρέθηκαν. Είναι πιο αργός από LSH/Hypercube, αλλά πολύ πιο αξιόπιστος. Συνολική αξιολόγηση: Πολύ καλή ισορροπία ταχύτητας και ακρίβειας, ιδανικός για υψηλή ποιότητα αναζήτησης με μικρό κόστος χρόνου.
- ✓ Ο IVF PQ έχει AF πολύ μεγάλο (100–1000+) → οι προσεγγιστικοί γείτονες απέχουν πολύ περισσότερο από τους πραγματικούς. Recall 0.46–0.66 → βρίσκει μόνο τους μισούς περίπου πραγματικούς γείτονες.

Ωστόσο, έχει ικανοποιητική ταχύτητα, ειδικά στο SIFT. Συνολική αξιολόγηση: Καλή ταχύτητα, μέτρια ακρίβεια, αλλά χαμηλή ποιότητα προσέγγισης λόγω υψηλού AF — πιθανώς χρειάζεται λιγότερη συμπίεση (π.χ. λιγότερα subquantizers ή περισσότερα bits ανά κέντρο).


Παρακάτω δίνονται και διαγράμματα για καλύτερη οπτικοποίηση των διαφορών των αλγορίθμων:




Εικόνα 2: Διάγραμμα AF με default τιμές




Εικόνα 3: Διάγραμμα Recall με default τιμές




Εικόνα 4: Διάγραμμα QPS με default τιμές



Εικόνα 5: Διάγραμμα $t_{Approximate}$ με default τιμές



Εικόνα 6: Διάγραμμα t_{True} με default τιμές



Εικόνα 7: Διάγραμμα Trade-off με default τιμές

Υπολογισμός καλύτερων k clusters μέσω silhouette

Για την καλύτερη στοιχειοθέτηση του συνόλου των φάσεων της πειραματικής ανάλυσης, αποφασίσαμε να υπολογίζουμε τα καλύτερα k clusters ξεχωριστά στον πρόγραμμά μας. Ειδικότερα, ο υπολογισμός του σκορ σιλουέτας έγινε για μη κανονικοποιημένα δεδομένα mnist και κανονικοποιημένα sift όπως ακριβώς δίνονται στην εκφώνηση.

Παρακάτω δίνεται ο πίνακας για τον υπολογισμό του σκορ σιλουέτας όπως ακριβώς παράγεται από το πρόγραμμα:

	A	B	C
1	k	silhouette	type
2	2	0.28	sift
3	5	0.11	sift
4	10	0.08	sift
5	50	0.04	sift
6	100	0.04	sift
7	200	0.03	sift
8	500	0.05	sift
9	2	0.09	mnist
10	5	0.07	mnist
11	10	0.08	mnist
12	50	0.06	mnist
13	100	0.05	mnist
14	200	0.05	mnist
15	500	0.05	mnist

Εικόνα 8: Πίνακας με silhouette score για kclusters

Όπως ήδη γνωρίζουμε από την θεωρία το καλύτερο σκορ σιλουέτας είναι αυτό που βρίσκεται κοντά στην μονάδα. Από τον παραπάνω πίνακα της **Εικόνας 8** (Πίνακας με silhouette score για kclusters), εμφανίζεται πως το καλύτερο k για clustering είναι το $k=2$, γιατί τότε τα αντικείμενα έχουν ανατεθεί καλύτερα στην σωστή τους συσταδοποίηση, δηλαδή στο πιο κοντινό τους κεντροειδές.

Διαγράμματα και πίνακας με Ά φάση αλλαγών

Σε αυτή την φάση αυξάνουμε λίγο ορισμένες παραμέτρους συνδυαστικά σε κάθε αλγόριθμο για να παρατηρήσουμε την συμπεριφορά του. Όσο για τα k χρησιμοποιήσαμε το καλύτερο που προέκυψε από το silhouette score. Κατά τα άλλα όλες οι υπόλοιπες παράμετροι και flags παραμένουν ίδια.

Ειδικότερα, για τη μέθοδο **LSH (Locality Sensitive Hashing)** χρησιμοποιήθηκαν οι εξής τιμές:

- $k = 8$ (αριθμός συναρτήσεων κατακερματισμού ανά πίνακα)

- **L = 10** (αριθμός πινάκων κατακερματισμού)
- **w = 1000** (δεκαδικός αριθμός του μήκους του κελιού επί της ευθείας προβολής)

Έπειτα, για τη μέθοδο **Hypercube** χρησιμοποιήθηκαν οι εξής τιμές:

- **kproj = 18** (διάσταση προβολής σημείων)
- **M = 100** (μέγιστο επιτρεπόμενο πλήθος υποψήφιων σημείων προς έλεγχο)
- **probes = 5** (το μέγιστο επιτρεπόμενο πλήθος κορυφών του υπερκύβου προς έλεγχο)
- **w = 1000** (δεκαδικός αριθμός του μήκους του κελιού επί της ευθείας προβολής)

Υστερα, για τη μέθοδο **IVF FLAT** χρησιμοποιήθηκαν οι εξής τιμές:

- **kclusters = 2**, (ο αριθμός των clusters που θα δημιουργηθούν,)
- **nprobe = 10** (ο αριθμός των πλησιέστερων clusters που θα ελεγχθούν κατά την αναζήτηση)

Τέλος, για τη μέθοδο **IVF PQ** χρησιμοποιήθηκαν οι εξής τιμές:

- **kclusters = 2**, (ο αριθμός των clusters που θα δημιουργηθούν,)
- **nprobe = 10** (ο αριθμός των πλησιέστερων clusters που θα ελεγχθούν κατά την αναζήτηση)
- **M = 32** (ο αριθμός των υποδιανυσμάτων M για τον Κβαντισμό Γινομένου)

	A	B	C	D	E	F	G	H
1	Method	Dataset	Range Search	Average AF	Recall@N	QPS	tApproximateA	tTrueAverage
2	IVFPQ	MNIST	True	1,208.54	0.65	1,571.46	0.34	4.03
3	IVFPQ	SIFT	True	208.14	0.82	2,327.62	0.24	0.67
4	HYPERCUBE	MNIST	False	0.99	0.02	48,428.33	0.02	8.93
5	HYPERCUBE	SIFT	False	1.45	0.16	21,786.73	0.04	1.72
6	IVFPQ	MNIST	False	1,208.54	0.65	2,872.92	0.34	4.04
7	IVFFLAT	MNIST	True	1	1	62.87	7.97	8.55
8	HYPERCUBE	MNIST	True	0.99	0.02	26,618.79	0.02	9.04
9	IVFFLAT	MNIST	False	1	1	124.98	7.98	9.76
10	IVFFLAT	SIFT	False	1	1	795.89	1.25	1.50
11	IVFPQ	SIFT	False	208.14	0.82	5,214.07	0.19	0.78
12	LSH	MNIST	True	0.24	0	7,759.71	0.06	9.03
13	LSH	MNIST	False	0.24	0	15,937.74	0.06	8.52
14	HYPERCUBE	SIFT	True	1.45	0.16	12,566.81	0.04	2.17
15	LSH	SIFT	True	1.01	0.86	784.72	0.67	1.77
16	IVFFLAT	SIFT	True	1	1	395.69	1.32	1.44
17	LSH	SIFT	False	1.01	0.86	1,959.75	0.50	1.44

Εικόνα 9: Πίνακας στην Α φάση


Σύμφωνα λοιπόν με τον πίνακα της **Εικόνας 9** (Πίνακας στην Α φάση):

- ✓ Ο LSH αποτυγχάνει πλήρως στο MNIST (Recall=0), παρότι είναι αρκετά γρήγορο. Ενδεχομένως οι παράμετροι hashing να μην προσαρμόστηκαν σωστά. Δεν είναι αξιόπιστο για αυτό το dataset. Πολύ καλύτερη συμπεριφορά στο SIFT: υψηλό Recall (0.86) με καλό χρόνο. Καλή ισορροπία ακρίβειας/ταχύτητας, παρότι δεν φτάνει IVFFLAT. Ιδανικό για approximate queries σε μεγάλα διανυσματικά δεδομένα.
- ✓ Ο Hypercube είναι εξαιρετικά γρήγορος (QPS > 25K–48K), αλλά με πολύ χαμηλό Recall (0.02). Αυτό δείχνει ότι εντοπίζει ελάχιστα σωστά κοντινά σημεία. Παρά την ταχύτητα, η ποιότητα αποτελεσμάτων είναι ανεπαρκής. Χρήσιμος μόνο για περιπτώσεις που προέχει η ταχύτητα. Στο SIFT αποδίδει λίγο καλύτερα (Recall 0.16), αλλά και πάλι χαμηλή ακρίβεια. Η ταχύτητα είναι πολύ υψηλή, οπότε ενδείκνυται για πολύ μεγάλες βάσεις ή pre-filtering στα στάδια αναζήτησης.


- ✓ Ο IVFFLAT επιτυγχάνει τέλεια ακρίβεια ($\text{Recall}=1.0$) και $\text{AF}=1.0$, που σημαίνει ότι βρίσκει ακριβώς τα ίδια σημεία με τον brute-force. Οι χρόνοι είναι αρκετά σταθεροί, με τη μη-range αναζήτηση (False) να έχει διπλάσιο QPS, δηλαδή ταχύτερη επεξεργασία. Το κόστος χρόνου είναι αναμενόμενο, αλλά η ακρίβεια βέλτιστη. Ιδανικός για μικρά datasets ή περιπτώσεις που απαιτείται 100% ακρίβεια. Στο SIFT η απόδοση είναι παρόμοια — τέλεια ακρίβεια και απόδοση, αλλά με πολύ μεγαλύτερο QPS λόγω μικρότερου υπολογιστικού κόστους ανά query. Πολύ αποτελεσματικός και ακριβής αλγόριθμος, με ταχύτητα σχεδόν διπλάσια στο non-range mode.
- ✓ Ο IVFPQ στο MNIST είναι αρκετά προσεγγιστικός με μέτριο Recall (0.65). Ωστόσο, είναι πολύ ταχύτερος ($\text{QPS} > 1500\text{--}2800$), με μέσο χρόνο ανά query $\sim 0.34\text{s}$, δηλαδή 10x ταχύτερος από IVFFLAT. Καλή ισορροπία ταχύτητας/ακρίβειας. Το $\text{AF}>1000$ δείχνει ότι το indexing οδηγεί σε αρκετά διαφορετικές αποστάσεις (όχι τέλεια αναπαράσταση). Στο SIFT αποδίδει πολύ καλύτερα — $\text{Recall}=0.82$ με πολύ χαμηλό χρόνο, $\sim 0.2\text{s}$. Εξαιρετική ταχύτητα με αποδεκτή απώλεια ακρίβειας. Ιδανικός για μεγαλύτερα datasets όπου μικρή απώλεια Recall είναι ανεκτή.

Στη Α φάση των πειραμάτων παρατηρείται συνολική βελτίωση της απόδοσης και της σταθερότητας των αλγορίθμων. Ο IVFFlat παραμένει η πιο αξιόπιστη και ακριβής μέθοδος, επιτυγχάνοντας σταθερά τέλεια αποτελέσματα. Ο LSH παρουσιάζει σημαντική βελτίωση στο SIFT, γεγονός που υποδηλώνει ότι αποδίδει καλύτερα σε δεδομένα υψηλής διάστασης. Ο IVFPQ εμφανίζει ελαφρά βελτίωση στην ακρίβεια, αν και εξακολουθεί να χαρακτηρίζεται από υψηλό Average Factor (AF), ενώ ο Hypercube διατηρεί εξαιρετικά υψηλή ταχύτητα εις βάρος όμως της ακρίβειας. Συνολικά, οι νέες ρυθμίσεις οδηγούν σε πιο ισορροπημένα και ρεαλιστικά αποτελέσματα, με αισθητή βελτίωση της αποτελεσματικότητας των προσεγγιστικών μεθόδων έναντι της αρχικής φάσης.


Παρακάτω δίνονται και διαγράμματα για καλύτερη οπτικοποίηση των διαφορών των αλγορίθμων:




Εικόνα 10: Διάγραμμα AF Ά φάσης




Εικόνα 11: Διάγραμμα Recall Α φάσης




Εικόνα 12: Διάγραμμα QPS Α φάσης



Εικόνα 13: Διάγραμμα $t_{Approximate}$ Α φάσης



Εικόνα 14: Διάγραμμα t_{True} Α φάσης



Εικόνα 15: Διάγραμμα Trade-off Α φάσης

Διαγράμματα και πίνακας με Β φάση αλλαγών

Σε αυτή την φάση αυξάνουμε λίγο παραπάνω ορισμένες παραμέτρους συνδυαστικά σε κάθε αλγόριθμο για να παρατηρήσουμε την συμπεριφορά του. Κατά τα άλλα όλες οι υπόλοιπες παράμετροι και flags παραμένουν ίδια.

Ειδικότερα, για τη μέθοδο **LSH (Locality Sensitive Hashing)** χρησιμοποιήθηκαν οι εξής τιμές:

- **k = 12** (αριθμός συναρτήσεων κατακερματισμού ανά πίνακα)
- **L = 10** (αριθμός πινάκων κατακερματισμού)
- **w = 1500** (δεκαδικός αριθμός του μήκους του κελιού επί της ευθείας προβολής)

Έπειτα, για τη μέθοδο **Hypercube** χρησιμοποιήθηκαν οι εξής τιμές:

- **kproj = 18** (διάσταση προβολής σημείων)
- **M = 1000** (μέγιστο επιτρεπόμενο πλήθος υποψήφιων σημείων προς έλεγχο)
- **probes = 10** (το μέγιστο επιτρεπόμενο πλήθος κορυφών του υπερκύβου προς έλεγχο)
- **w = 1500** (δεκαδικός αριθμός του μήκους του κελιού επί της ευθείας προβολής)

Υστερα, για τη μέθοδο **IVF FLAT** χρησιμοποιήθηκαν οι εξής τιμές:

- **kclusters = 2**, (ο αριθμός των clusters που θα δημιουργηθούν,)
- **nprobe = 15** (ο αριθμός των πλησιέστερων clusters που θα ελεγχθούν κατά την αναζήτηση)

Τέλος, για τη μέθοδο **IVF PQ** χρησιμοποιήθηκαν οι εξής τιμές:

- **kclusters = 2**, (ο αριθμός των clusters που θα δημιουργηθούν,)
- **nprobe = 15** (ο αριθμός των πλησιέστερων clusters που θα ελεγχθούν κατά την αναζήτηση)
- **M = 32** (ο αριθμός των υποδιανυσμάτων M για τον Κβαντισμό Γινομένου)

	A	B	C	D	E	F	G	H
1	Method	Dataset	Range Search	Average AF	Recall@N	QPS	tApproximateA	tTrueAverage
2	IVFPQ	MNIST	True	1,208.54	0.65	1,640.02	0.33	4.09
3	IVFPQ	SIFT	True	208.14	0.82	3,106.47	0.18	0.64
4	HYPERCUBE	MNIST	False	1.28	0.04	46,824.57	0.02	3.92
5	HYPERCUBE	SIFT	False	1.17	0.54	7,552.61	0.13	0.68
6	IVFPQ	MNIST	False	1,208.54	0.65	2,947.50	0.34	3.92
7	IVFFLAT	MNIST	True	1	1	120.42	4.15	3.88
8	HYPERCUBE	MNIST	True	1.28	0.04	24,764.03	0.02	4.49
9	IVFFLAT	MNIST	False	1	1	238.77	4.18	4.34
10	IVFFLAT	SIFT	False	1	1	1,714.27	0.58	0.73
11	IVFPQ	SIFT	False	208.14	0.82	5,320.95	0.18	0.68
12	LSH	MNIST	True	0.24	0	7,759.71	0.06	9.03
13	LSH	MNIST	False	0.24	0	15,937.74	0.06	8.52
14	HYPERCUBE	SIFT	True	1.17	0.54	4,772.68	0.11	0.72
15	LSH	SIFT	True	1.01	0.86	784.72	0.67	1.77
16	IVFFLAT	SIFT	True	1	1	890.82	0.58	0.68
17	LSH	SIFT	False	1.01	0.86	1,959.75	0.50	1.44

Εικόνα 16: Πίνακας στην 'B φάση

Σύμφωνα λοιπόν με τον πίνακα της **Εικόνας 16** (Πίνακας στην 'B φάση):


- ✓ Ο LSH έχει πολύ χαμηλή ακρίβεια στο MNIST (Recall@N = 0.0), κάτι που δείχνει αποτυχία εντοπισμού σωστών γειτόνων σε χαμηλότερες διαστάσεις. Στο SIFT, αντιθέτως, η απόδοση είναι σαφώς βελτιωμένη, με Recall@N = 0.86 και $AF \approx 1.0$, δηλαδή τα αποτελέσματα είναι και κοντά στις πραγματικές αποστάσεις. Η ταχύτητά του είναι καλή (QPS ≈ 784 –1959), με χρόνο αναζήτησης <1 ms. Συμπέρασμα: Ο LSH αποδίδει πολύ καλά σε δεδομένα υψηλής διάστασης (SIFT) αλλά αποτυγχάνει στο MNIST. Είναι κατάλληλος για high-dimensional feature spaces.
- ✓ Ο Hypercube παρουσιάζει ιδιαίτερα υψηλό QPS (μέχρι ~47K στο MNIST και ~7.5K στο SIFT), γεγονός που τον καθιστά τον ταχύτερο αλγόριθμο. Ωστόσο, η Recall@N είναι πολύ χαμηλή στο MNIST (0.04) και μέτρια στο SIFT (0.54). Το Average AF κυμαίνεται κοντά στη μονάδα (1.17–1.27), δηλαδή οι υπολογισμένες αποστάσεις δεν αποκλίνουν σημαντικά, αλλά οι σωστοί γείτονες δεν εντοπίζονται με συνέπεια. Συμπέρασμα: Ο

Hypercube είναι εξαιρετικά ταχύς αλλά ανακριβής. Ενδείκνυται μόνο για εφαρμογές όπου προέχει η ταχύτητα αναζήτησης έναντι της ποιότητας αποτελεσμάτων.


- ✓ Ο IVFFlat διατηρεί την κορυφαία ακρίβεια σε όλα τα πειράματα, με Average AF = 1.0 και Recall@N = 1.0 τόσο σε MNIST όσο και σε SIFT, ανεξάρτητα από την ενεργοποίηση του range search. Παρά τη μικρή αύξηση του χρόνου ανά ερώτημα στο SIFT (περίπου 0.58–0.68 ms) έναντι του MNIST (4–4.3 ms), τα αποτελέσματα παραμένουν εξαιρετικά σταθερά. Ο ρυθμός εκτέλεσης (QPS) αυξάνεται σημαντικά στο SIFT λόγω του μικρότερου κόστους ανά query. Συμπέρασμα: Ο πιο αξιόπιστος αλγόριθμος, συνδυάζοντας τέλεια ακρίβεια με ικανοποιητική ταχύτητα, ιδανικός για baseline ή high-precision εφαρμογές.
- ✓ Ο IVFPQ δείχνει πολύ υψηλό Average AF (≈ 1208 στο MNIST, ≈ 208 στο SIFT), πράγμα που σημαίνει ότι τα προσεγγιστικά αποτελέσματα διαφέρουν σημαντικά από τα πραγματικά. Ωστόσο, η Recall@N είναι μέτρια έως καλή (0.65 στο MNIST και 0.82 στο SIFT), δείχνοντας ότι συχνά βρίσκει τα σωστά σημεία αλλά με υπερεκτίμηση των αποστάσεων. Η ταχύτητά του (QPS) είναι υψηλή, ειδικά στο SIFT, και ο χρόνος αναζήτησης χαμηλός (≈ 0.18 – 0.33 ms). Συμπέρασμα: Ο IVFPQ είναι ταχύς αλλά όχι αξιόπιστος σε επίπεδο απόλυτων αποστάσεων. Είναι κατάλληλος όταν προέχει η ταχύτητα και όχι η ακριβής εκτίμηση απόστασης.

Οι βελτιωμένες ρυθμίσεις οδηγούν σε πιο ισορροπημένη συμπεριφορά των προσεγγιστικών αλγορίθμων, με το IVFFlat να αποτελεί το σημείο αναφοράς, τον LSH να ξεχωρίζει στο SIFT, και τον Hypercube να προσφέρει εξαιρετική ταχύτητα με συμβιβασμό στην ακρίβεια.


Παρακάτω δίνονται και διαγράμματα για καλύτερη οπτικοποίηση των διαφορών των αλγορίθμων:




Εικόνα 17: Διάγραμμα AF 'B φάσης




Εικόνα 18: Διάγραμμα Recall 'B φάσης




Εικόνα 19: Διάγραμμα QPS 'B' φάσης



Εικόνα 20: Διάγραμμα $t_{Approximate}$ 'B' φάσης



Εικόνα 21: Διάγραμμα *True* 'B φάσης



Εικόνα 22: Διάγραμμα Trade-off 'B φάσης

Διαγράμματα και πίνακας με 'T φάση αλλαγών

Αυτή αποτελεί την τελική φάση των πειραμάτων μας, στην οποία αποφασίσαμε να αυξάνουμε ακόμα περισσότερο ορισμένες παραμέτρους συνδυαστικά σε κάθε αλγόριθμο για να παρατηρήσουμε την συμπεριφορά του. Κατά τα άλλα όλες οι υπόλοιπες παράμετροι και flags παραμένουν ίδια.

Ειδικότερα, για τη μέθοδο **LSH (Locality Sensitive Hashing)** χρησιμοποιήθηκαν οι εξής τιμές:

- **k = 16** (αριθμός συναρτήσεων κατακερματισμού ανά πίνακα)
- **L = 10** (αριθμός πινάκων κατακερματισμού)

- **w = 2000** (δεκαδικός αριθμός του μήκους του κελιού επί της ευθείας προβολής)

Έπειτα, για τη μέθοδο **Hypercube** χρησιμοποιήθηκαν οι εξής τιμές:

- **kproj = 22** (διάσταση προβολής σημείων)
- **M = 5000** (μέγιστο επιτρεπόμενο πλήθος υποψήφιων σημείων προς έλεγχο)
- **probes = 12** (το μέγιστο επιτρεπόμενο πλήθος κορυφών του υπερκύβου προς έλεγχο)
- **w = 2000** (δεκαδικός αριθμός του μήκους του κελιού επί της ευθείας προβολής)

Υστερα, για τη μέθοδο **IVF FLAT** χρησιμοποιήθηκαν οι εξής τιμές:

- **kclusters = 2**, (ο αριθμός των clusters που θα δημιουργηθούν,)
- **nprobe = 20** (ο αριθμός των πλησιέστερων clusters που θα ελεγχθούν κατά την αναζήτηση)

Τέλος, για τη μέθοδο **IVF PQ** χρησιμοποιήθηκαν οι εξής τιμές:

- **kclusters = 2**, (ο αριθμός των clusters που θα δημιουργηθούν,)
- **nprobe = 20** (ο αριθμός των πλησιέστερων clusters που θα ελεγχθούν κατά την αναζήτηση)
- **M = 64** (ο αριθμός των υποδιανυσμάτων M για τον Κβαντισμό Γινομένου)

	A	B	C	D	E	F	G	H
1	Method	Dataset	Range Search	Average AF	Recall@N	QPS	tApproximateA	tTrueAverage
2	IVFPQ	MNIST	True	1,209.96	0.78	1,403.04	0.38	4.04
3	IVFPQ	SIFT	True	200.05	0.92	1,450.19	0.38	0.72
4	HYPERCUBE	MNIST	False	1.17	0.02	39,401.35	0.02	3.82
5	HYPERCUBE	SIFT	False	1.09	0.62	6,318.40	0.16	0.64
6	IVFPQ	MNIST	False	1,209.96	0.78	2,772.50	0.36	3.82
7	IVFFLAT	MNIST	True	1	1	119.57	4.17	3.87
8	HYPERCUBE	MNIST	True	1.17	0.02	21,968.04	0.02	3.79
9	IVFFLAT	MNIST	False	1	1	242.05	4.12	3.82
10	IVFFLAT	SIFT	False	1	1	1,828.68	0.54	0.65
11	IVFPQ	SIFT	False	200.05	0.92	3,346.19	0.30	0.63
12	LSH	MNIST	True	0.10	0.03	8,188.25	0.06	4.08
13	LSH	MNIST	False	0.10	0.03	17,033.28	0.06	3.97
14	HYPERCUBE	SIFT	True	1.09	0.62	3,181.17	0.16	0.66
15	LSH	SIFT	True	1.00	0.96	1,458.86	0.36	0.66
16	IVFFLAT	SIFT	True	1	1	770.28	0.66	0.67
17	LSH	SIFT	False	1.00	0.96	2,802.88	0.35	0.69

Εικόνα 23: Πίνακας στην Τ φάση

Σύμφωνα λοιπόν με τον πίνακα της **Εικόνας 23** (Πίνακας στην Τ φάση):


- ✓ Ο LSH παρουσιάζει μεγάλη αντίθεση μεταξύ MNIST και SIFT. Στο MNIST, η απόδοση παραμένει χαμηλή ($\text{Recall@N} = 0.03$, $\text{AF} \approx 0.1$), κάτι που δείχνει αδυναμία να αποτυπώσει τη δομή των χαμηλότερων διαστάσεων. Αντίθετα, στο SIFT, αποδίδει εξαιρετικά: $\text{Recall@N} = 0.96$, $\text{AF} \approx 1.0$, με χρόνο αναζήτησης ~ 0.35 ms και $\text{QPS} > 1400$, ενώ χωρίς range search φτάνει σχεδόν 2800 QPS. Η επίδοση αυτή δείχνει ότι ο LSH εκμεταλλεύεται πλήρως τη στοχαστική φύση των hash functions σε high-dimensional embeddings, όπου τα σημεία διαχωρίζονται πιο φυσικά. Συμπέρασμα: Ο LSH διαπρέπει στα δεδομένα υψηλής διάστασης (SIFT), αλλά αποτυγχάνει πλήρως στα χαμηλότερα. Ιδανικός για σύνολα χαρακτηριστικών τύπου εικόνας ή deep features.
- ✓ Ο Hypercube παραμένει ο ταχύτερος αλγόριθμος με QPS 20K–39K στο MNIST και 3K–6K στο SIFT, επιβεβαιώνοντας τη σχεδόν στιγμιαία αναζήτηση. Η Recall@N στο MNIST είναι πολύ χαμηλή (0.02), γεγονός που τον καθιστά αναξιόπιστο για μικρότερες διαστάσεις, ενώ στο SIFT ανεβαίνει σημαντικά (0.62), δείχνοντας βελτίωση όταν το dataset έχει

μεγαλύτερη διασπορά χαρακτηριστικών. Το Average AF είναι κοντά στη μονάδα (1.08–1.17), ένδειξη ότι οι αποστάσεις είναι κατά μέσο όρο σωστά υπολογισμένες, όμως τα αποτελέσματα δεν είναι ποιοτικά. Συμπέρασμα: Ο Hypercube είναι αστραπιαίος και κατάλληλος για εφαρμογές μεγάλης κλίμακας, αλλά με συμβιβασμό στην ακρίβεια. Αξιοποιείται όταν το ζητούμενο είναι ταχύτητα και προσέγγιση, όχι απόλυτη ορθότητα.


- ✓ Ο IVFFlat παραμένει σταθερά ο πιο αξιόπιστος αλγόριθμος, επιτυγχάνοντας τέλεια ακρίβεια (Average AF = 1.0, Recall@N = 1.0) τόσο στο MNIST όσο και στο SIFT, ανεξαρτήτως του αν το range search είναι ενεργό ή όχι. Στο MNIST, ο χρόνος αναζήτησης ανά ερώτημα κυμαίνεται γύρω στα 4.1 ms, με QPS $\approx$ 120–240, ενώ στο SIFT είναι πολύ μικρότερος ($\sim$ 0.54–0.66 ms) και το QPS εκτοξεύεται έως 1800. Η συμπεριφορά αυτή επιβεβαιώνει την ιδανική αναλογία ακρίβειας–απόδοσης, ειδικά σε datasets με διαφορετική διάσταση, όπου το IVFFlat δείχνει αξιοθαύμαστη σταθερότητα. Συμπέρασμα: Ο IVFFlat είναι ο “χρυσός κανόνας” μεταξύ ταχύτητας και ακρίβειας· αποτελεί τη βάση για σύγκριση όλων των άλλων μεθόδων, με σταθερή και καθολικά άριστη συμπεριφορά.
- ✓ Ο IVFPQ διατηρεί τις τάσεις των προηγούμενων δοκιμών, αλλά εμφανίζει βελτίωση στην ανάκληση (Recall@N) — 0.78 στο MNIST και 0.92 στο SIFT, ενώ το Average AF παραμένει πολύ μεγάλο ($\sim$ 1209 στο MNIST, $\sim$ 200 στο SIFT). Αυτό σημαίνει ότι, αν και βρίσκει τους σωστούς γείτονες, η εκτίμηση των αποστάσεων είναι παραμορφωμένη λόγω της κβαντοποίησης. Η ταχύτητα είναι εντυπωσιακή: στο MNIST επιτυγχάνει $\sim$ 1400–2800 QPS, με μέσο χρόνο <0.4 ms, ενώ στο SIFT φτάνει ακόμα υψηλότερα, μέχρι 3300 QPS, με χρόνο $\sim$ 0.29–0.38 ms. Συμπέρασμα: Ο IVFPQ είναι πολύ αποδοτικός, κλιμακώνεται καλά σε υψηλές διαστάσεις και αποτελεί εξαιρετική επιλογή για real-time εφαρμογές, με τίμημα όμως την ακρίβεια απόστασης.

Συνολικά, οι νέες μετρήσεις δείχνουν ότι οι προσεγγιστικοί αλγόριθμοι έχουν πλέον σταθεροποιηθεί· ο IVFFlat και ο IVFPQ προσφέρουν τη βέλτιστη ισορροπία ακρίβειας–απόδοσης, ο Hypercube αναδεικνύεται σε ταχύ εργαλείο μαζικών αναζητήσεων, ενώ ο LSH εξειδικεύεται στα high-dimensional embeddings, επιβεβαιώνοντας την ευρεία αλλά διαφοροποιημένη ισχύ του φάσματος των ANN μεθόδων.


Παρακάτω δίνονται και διαγράμματα για καλύτερη οπτικοποίηση των διαφορών των αλγορίθμων:




Εικόνα 24: Διάγραμμα AF 'T φάσης




Εικόνα 25: Διάγραμμα Recall Τ φάσης




Εικόνα 26: Διάγραμμα QPS Τ'φάσης



Εικόνα 27: Διάγραμμα $t_{Approximate}$ Έφάσης



Εικόνα 28: Διάγραμμα t_{True} Γ φάσης



Εικόνα 29: Διάγραμμα Trade-off Τ φάσης